



Módulo 2 – Introdução à Arquitetura de Nuvem

Este módulo apresenta os fundamentos da computação em nuvem e a infraestrutura global da AWS, fornecendo a base conceitual necessária para projetar soluções escaláveis, resilientes e bem arquitetadas.

AWS CLOUD FOUNDATIONS

Objetivos de Aprendizagem


Ao final deste módulo, o aluno será capaz de:

01	02	03
Arquitetura em Nuvem	Well-Architected Framework	Infraestrutura Global
Compreender como funciona uma arquitetura em nuvem e a estrutura global da AWS.	Identificar os pilares do AWS Well-Architected Framework e aplicar boas práticas na criação de soluções.	Diferenciar Regiões, Availability Zones e Edge Locations, compreendendo como a AWS entrega alta disponibilidade.

Antes da Computação em Nuvem

Durante muitos anos, empresas mantinham seus próprios servidores físicos. Uma infraestrutura tradicional era composta por sala de servidores, servidores web, bancos de dados, firewalls, storage, switches e nobreaks — tudo gerenciado pela equipe interna de TI.

Para lançar um novo sistema, a empresa precisava adquirir servidor, rack, nobreak, switches, licenças, firewall, armazenamento e sistema operacional. Somente depois seria possível instalar o software. **Esse processo frequentemente levava semanas ou meses.**



Problemas do Modelo Tradicional: Alto Investimento Inicial

O principal obstáculo do modelo on-premises era o **CAPEX (Capital Expenditure)** — todo o investimento precisava ser realizado antes mesmo do sistema entrar em funcionamento.

R\$30K

Servidor

Custo de aquisição de hardware de servidor físico.

R\$80K

Storage

Solução de armazenamento corporativo.

R\$25K

Firewall

Equipamento de segurança de rede.

R\$175K

Total

Investimento inicial antes de qualquer linha de código em produção.

Baixa Escalabilidade e Subutilização

O Problema da Black Friday

Um e-commerce recebe 500 usuários por dia. Durante a Black Friday, esse número salta para 500.000. Os servidores não conseguem atender toda a demanda, resultando em lentidão, indisponibilidade e perda de vendas.


Subutilização Crônica

Um servidor que utiliza apenas 20% da CPU durante quase todo o ano precisa ser superdimensionado para suportar um pico de apenas uma semana. Durante 51 semanas, o equipamento permanece praticamente ocioso — capital imobilizado sem retorno.

 Infraestrutura dimensionada para o pico significa desperdício durante 98% do tempo.

Tempo de Implantação: Um Gargalo Estratégico

No modelo tradicional, adquirir servidores envolvia um longo processo burocrático e operacional. Cada etapa consumia tempo precioso antes que qualquer valor pudesse ser entregue ao negócio.



Todo esse processo poderia durar meses — tempo em que concorrentes mais ágeis já estariam operando.

Surge a Computação em Nuvem

Em vez de comprar servidores, empresas passaram a alugá-los. Essa mudança alterou completamente o modelo financeiro da TI corporativa.

Modelo Antigo: CAPEX

Grandes investimentos de capital realizados antecipadamente, com ativos físicos depreciando ao longo do tempo. O risco financeiro recaía inteiramente sobre a empresa.

Modelo Novo: OPEX

Pagamento pelo uso efetivo. Um servidor ligado por 5 horas gera cobrança apenas por essas 5 horas. Servidor desligado — praticamente sem custo de computação. **Esse conceito revolucionou a área de TI.**

O que é Cloud Computing?

Computação em nuvem é um modelo que permite acesso **sob demanda** a recursos computacionais compartilhados por meio da internet, com provisionamento rápido e gerenciamento simplificado. A infraestrutura deixa de ser um ativo físico e passa a ser consumida como serviço.



Computação e Redes

Servidores, redes e bancos de dados provisionados em minutos.



Inteligência Artificial

Serviços de IA, machine learning e análise de dados prontos para uso.



Ferramentas de Dev

Filas de mensagens, monitoramento e ferramentas de desenvolvimento integradas.

Características Fundamentais e Modelos de Serviço

Cinco Características Essenciais

- **Autosserviço sob demanda:** criação de recursos sem intervenção manual do provedor.
- **Amplo acesso à rede:** acesso via internet por diferentes dispositivos.
- **Pool compartilhado:** infraestrutura física compartilhada de forma segura e isolada.
- **Elasticidade rápida:** expansão ou redução conforme a demanda.
- **Serviço mensurável:** cobrança baseada no consumo efetivo.

Três Modelos de Serviço

IaaS

Infraestrutura virtualizada. Cliente gerencia SO e aplicações.
Exemplo: Amazon EC2.

PaaS

Provedor gerencia o ambiente de execução. Cliente foca no desenvolvimento.

SaaS

Aplicação pronta para consumo. Sem gerenciamento de servidores ou infraestrutura.



A Infraestrutura Global da AWS

A AWS é composta por centenas de data centers distribuídos ao redor do mundo, conectados pelo **AWS Global Backbone** — uma rede privada de fibra óptica de alta velocidade projetada para oferecer baixa latência, alta disponibilidade e segurança superior à Internet pública.

Regiões

Áreas geográficas independentes com infraestrutura completa de serviços AWS.

Availability Zones

Múltiplos data centers fisicamente separados dentro de cada Região.

Edge Locations

Pontos de presença distribuídos globalmente para entrega de conteúdo com baixa latência.

Regiões AWS: Conceito e Identificação

Uma **Região** é uma área geográfica independente onde a AWS mantém infraestrutura completa — data centers, redes, armazenamento, computação, bancos de dados e segurança. Cada Região opera de forma isolada, de modo que um problema em uma Região normalmente não afeta as demais.

Região	Código	Destaque
Norte da Virgínia	us-east-1	Região mais antiga e completa da AWS
São Paulo	sa-east-1	Principal opção para empresas brasileiras
Frankfurt	eu-central-1	Conformidade com GDPR europeu
Tóquio	ap-northeast-1	Hub para mercado asiático
Sydney	ap-southeast-2	Cobertura para Oceania

Esses códigos aparecem constantemente na criação de recursos, APIs, SDKs e ferramentas de automação.

Por que Existem Várias Regiões?

1

Latência

Quanto mais próximo o servidor do usuário, menor o tempo de resposta. Um usuário em Campinas terá experiência muito superior utilizando `sa-east-1` em vez de `ap-northeast-1`.

2

Legislação e Soberania

Dados bancários, prontuários médicos e informações governamentais frequentemente precisam permanecer dentro do território nacional por exigência legal.

3

Disaster Recovery

Organizações críticas replicam dados entre Regiões distintas. Se uma Região inteira ficar indisponível, outra assume a operação continuamente.

4

Disponibilidade de Serviços

Nem todos os serviços AWS estão disponíveis em todas as Regiões. Novos recursos são lançados gradualmente — verificar a disponibilidade regional é etapa obrigatória no planejamento arquitetural.

Availability Zones: Alta Disponibilidade na Prática

Uma das maiores inovações da AWS é o conceito de **Availability Zone (AZ)**. Cada Região é formada por múltiplas AZs fisicamente separadas, cada uma com energia elétrica independente, refrigeração própria, conectividade redundante e proteção física dedicada.

Arquitetura de Risco: Single AZ

Uma aplicação em apenas uma AZ fica completamente indisponível diante de qualquer falha elétrica ou de hardware naquele local. Não há redundância, não há recuperação automática.

⊗ Nunca hospede aplicações críticas em uma única Availability Zone.

Arquitetura Resiliente: Multi-AZ

Com a aplicação distribuída entre três AZs e um Load Balancer na frente, a falha de uma AZ é transparente para o usuário. O balanceador redireciona o tráfego automaticamente para as AZs saudáveis — esse é o princípio de **Alta Disponibilidade (High Availability)**.

Alta Disponibilidade × Tolerância a Falhas

Esses termos são frequentemente confundidos em entrevistas técnicas e certificações. Compreender a diferença é essencial para o arquiteto de soluções.

Alta Disponibilidade (HA)

Busca **reduzir ao máximo** o tempo de indisponibilidade por meio de redundância e recuperação rápida. Pode haver uma breve interrupção perceptível durante o failover.

Tolerância a Falhas (FT)

A aplicação **continua operando sem interrupção perceptível** mesmo diante da falha de um componente. Arquiteturas FT são mais complexas e custosas, adotadas em sistemas financeiros, de saúde e telecomunicações.

Exercício arquitetural: Uma loja virtual atende clientes em todo o Brasil e está hospedada em apenas uma instância EC2 em uma única AZ de São Paulo. Quais riscos essa arquitetura apresenta? Como redesenhá-la para maior disponibilidade e resiliência?

O Problema da Distância e a Latência

Mesmo com servidores funcionando perfeitamente em São Paulo, usuários fisicamente distantes percebem lentidão. A razão é física: dados percorrem milhares de quilômetros por fibras ópticas, e a velocidade da luz tem limites.

10ms

Campinas → São Paulo

Latência típica para usuários locais.

120ms

Nova York → São Paulo

Latência transatlântica perceptível.

250ms

Tóquio → São Paulo


Latência transpacífica significativa.

Uma única página web pode gerar dezenas ou centenas de requisições (HTML, CSS, JS, imagens, APIs). Com alta latência em cada requisição, o carregamento torna-se perceptivelmente mais lento para o usuário final.



Edge Locations e Amazon CloudFront

A solução da AWS para o problema da distância são as **Edge Locations** — pontos de presença distribuídos estrategicamente pelo mundo para aproximar conteúdos dos usuários. O serviço que as utiliza é o **Amazon CloudFront**, uma Content Delivery Network (CDN) integrada a S3, EC2, Load Balancers e APIs.



Cache Miss

Cache Hit

Na primeira requisição (Cache Miss), a Edge Location busca o conteúdo na origem. Nas requisições seguintes (Cache Hit), o conteúdo é entregue diretamente do cache local, reduzindo latência e carga sobre os servidores de origem.

Cache Hit, Cache Miss e AWS Global Backbone

Cache Miss vs. Cache Hit

Cache Miss

Conteúdo ausente na Edge Location. Busca realizada na origem. Resultado: maior tempo de resposta.

Cache Hit

Conteúdo disponível localmente. Entrega imediata. Resultado: menor latência e melhor desempenho.

AWS Global Backbone

A maior parte da comunicação entre serviços AWS **não utiliza a Internet pública**. A AWS mantém uma vasta rede privada global de fibra óptica que conecta Regiões, AZs e Edge Locations, oferecendo menor latência, maior segurança, alta disponibilidade e comunicação previsível entre serviços.

Local Zones, AWS Outposts e AWS Wavelength



Local Zones

Aproximam infraestrutura AWS de grandes centros urbanos para cargas de trabalho que exigem latência ultrabaixa: edição de vídeo em tempo real, renderização gráfica, realidade aumentada, jogos online e simulações industriais. Diferentemente das Edge Locations, permitem executar cargas de trabalho completas.



AWS Outposts


Leva hardware gerenciado pela AWS para as instalações do cliente. Ideal para organizações com exigências legais, regulatórias ou operacionais que impedem a migração total para a nuvem. Possibilita arquitetura híbrida com gerenciamento unificado.



AWS Wavelength

Integra serviços AWS diretamente à infraestrutura das operadoras de telecomunicações 5G. Projetado para aplicações com latências extremamente baixas: veículos autônomos, robótica, realidade aumentada e processamento em tempo real.

Visão Consolidada da Infraestrutura Global AWS



Essa arquitetura em camadas é o alicerce sobre o qual aplicações altamente disponíveis, resilientes e globalmente distribuídas são construídas na AWS. Cada camada tem um papel específico na entrega de desempenho e continuidade operacional.

Síntese do Módulo e Reflexão Arquitetural

Neste módulo, percorremos a evolução do modelo on-premises até a computação em nuvem, compreendemos a organização hierárquica da infraestrutura global da AWS e exploramos os mecanismos que garantem alta disponibilidade e baixa latência em escala global.

Questão para o arquiteto: Se você fosse projetar uma plataforma de streaming como a Netflix, atendendo usuários no Brasil, Estados Unidos e Japão com apenas uma Região AWS — quais riscos existiriam? Como distribuiria a infraestrutura? Em quais situações utilizaria CloudFront, múltiplas Availability Zones e replicação entre Regiões?

CAPEX → OPEX

Nuvem transforma investimento em despesa operacional baseada no consumo.

Regiões e AZs

Fundamento da resiliência e conformidade regulatória em arquiteturas AWS.

Edge e Backbone

CloudFront e rede privada global garantem desempenho consistente para usuários em qualquer lugar do mundo.